

Università degli Studi

Corso di Laurea in Informatica

Metodi Statistici per l'Informatica

Simulazione della Seconda Prova Parziale (Mock Test)

Nome e Cognome: _____

Numero di Matricola: _____

N.B. Tutte le risposte devono essere adeguatamente giustificate nel foglio di svolgimento. Il semplice riporto del risultato finale non è sufficiente per ottenere un punteggio positivo. I punteggi massimi per ciascun quesito sono indicati a fianco.

Esercizio 1 (Stima Puntuale e Consistenza) — [Totale: 7 punti]

Sia X_1, X_2, X_3, X_4 un campione casuale estratto da una popolazione con media μ e varianza σ^2 . Si considerino i seguenti due stimatori per la media della popolazione μ :

$$\hat{\mu}_1 = 0.15X_1 + 0.25X_2 + 0.35X_3 + 0.25X_4$$

$$\hat{\mu}_2 = 0.25X_1 + 0.25X_2 + 0.25X_3 + 0.25X_4$$

- (a) Calcolare il valore atteso di entrambi gli stimatori e determinare se sono stimatori non distorti (*unbiased*) per μ . [2]
- (b) Calcolare l'efficienza relativa dello stimatore $\hat{\mu}_2$ rispetto allo stimatore $\hat{\mu}_1$. Quale dei due stimatori risulta più efficiente? [2]
- (c) Si consideri ora il caso generale di un campione casuale di ampiezza n , $X_1, X_2, \dots, X_n$, e lo stimatore media campionaria $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$. Dimostrare che $\bar{X}_n$ è uno stimatore **consistente** per μ analizzando il comportamento del suo Errore Standard (*Standard Error*, SE) per $n \rightarrow \infty$, **senza utilizzare la formula o disuguaglianza di Chebyshev**. Spiegare chiaramente la relazione tra la non distorsione, il comportamento del SE e la consistenza. [3]

Esercizio 2 (Intervalli di Confidenza) — [Totale: 5 punti]

Un docente di Informatica vuole stimare il tempo medio giornaliero che gli studenti dedicano alla programmazione. A tale scopo, viene selezionato un campione casuale di $n = 16$ studenti, per i quali si osserva una media campionaria pari a $\bar{x} = 4.5$ ore e una deviazione standard campionaria corretta $s = 1.2$ ore. Si assuma che il tempo speso a programmare sia distribuito normalmente nella popolazione.

- (a) Calcolare un intervallo di confidenza al 95% per la media della popolazione μ . [3]
- (b) Determinare l'ampiezza campionaria minima necessaria per stimare la media della popolazione μ con un margine di errore non superiore a 0.3 ore, mantenendo un livello di confidenza del 95% (si assuma come stima della deviazione standard della popolazione il valore $s = 1.2$). [2]

Esercizio 3 (Test d'Ipotesi) — [Totale: 6 punti]

Un'azienda produttrice di microchip garantisce che la percentuale di componenti difettosi all'interno dei propri lotti di produzione è al massimo pari al 2% ($p \leq 0.02$). Un ingegnere informatico incaricato del controllo qualità analizza un campione casuale di $n = 600$ microchip, riscontrando che 18 di essi sono difettosi. Si vuole testare l'ipotesi nulla che l'affermazione del produttore sia vera.

- (a) Formulare il sistema di ipotesi corretto (nulla e alternativa) e calcolare il valore della statistica test e il rispettivo p -value. [3]
- (b) Determinare la soglia critica di rifiuto impostando un livello di significatività $\alpha = 0.05$. [2]
- (c) Alla luce dei risultati ottenuti, si deve rifiutare l'ipotesi nulla H_0 al livello di significatività del 5%? Commentare il risultato rispetto al reclamo dell'azienda. [1]

Soluzioni Dettagliate e Passaggi Svolti

Soluzione Esercizio 1

- (a) Per verificare la non distorsione, calcoliamo il valore atteso degli stimatori ricordando che $E[X_i] = \mu$ per ogni i :

$$\begin{aligned} E[\hat{\mu}_1] &= E[0.15X_1 + 0.25X_2 + 0.35X_3 + 0.25X_4] \\ &= 0.15E[X_1] + 0.25E[X_2] + 0.35E[X_3] + 0.25E[X_4] \\ &= (0.15 + 0.25 + 0.35 + 0.25)\mu = 1.00\mu = \mu. \end{aligned}$$

Dato che $E[\hat{\mu}_1] = \mu$, lo stimatore $\hat{\mu}_1$ è **non distorto**.

Analogamente per $\hat{\mu}_2$:

$$\begin{aligned} E[\hat{\mu}_2] &= E[0.25X_1 + 0.25X_2 + 0.25X_3 + 0.25X_4] \\ &= (0.25 + 0.25 + 0.25 + 0.25)\mu = 1.00\mu = \mu. \end{aligned}$$

Dato che $E[\hat{\mu}_2] = \mu$, anche lo stimatore $\hat{\mu}_2$ è **non distorto**.

- (b) Calcoliamo le varianze dei due stimatori, sapendo che le osservazioni sono indipendenti e quindi $V[X_i] = \sigma^2$:

$$\begin{aligned} V[\hat{\mu}_1] &= V[0.15X_1 + 0.25X_2 + 0.35X_3 + 0.25X_4] \\ &= 0.15^2V[X_1] + 0.25^2V[X_2] + 0.35^2V[X_3] + 0.25^2V[X_4] \\ &= (0.0225 + 0.0625 + 0.1225 + 0.0625)\sigma^2 = 0.27\sigma^2. \end{aligned}$$

Per lo stimatore $\hat{\mu}_2$ (che coincide con la media campionaria per $n = 4$):

$$\begin{aligned} V[\hat{\mu}_2] &= 0.25^2V[X_1] + 0.25^2V[X_2] + 0.25^2V[X_3] + 0.25^2V[X_4] \\ &= 4 \times 0.0625\sigma^2 = 0.25\sigma^2 = \frac{\sigma^2}{4}. \end{aligned}$$

L'efficienza relativa di $\hat{\mu}_2$ rispetto a $\hat{\mu}_1$ è data dal rapporto inverso delle loro varianze:

$$\text{EffRel}(\hat{\mu}_2, \hat{\mu}_1) = \frac{V[\hat{\mu}_1]}{V[\hat{\mu}_2]} = \frac{0.27\sigma^2}{0.25\sigma^2} = \frac{0.27}{0.25} = 1.08.$$

Poiché $\text{EffRel}(\hat{\mu}_2, \hat{\mu}_1) = 1.08 > 1$, lo stimatore $\hat{\mu}_2$ è **più efficiente** di $\hat{\mu}_1$ (ha infatti una varianza inferiore).

- (c) Lo stimatore media campionaria $\bar{X}_n$ per un campione di ampiezza n ha valore atteso $E[\bar{X}_n] = \mu$ (è non distorto) e varianza $V[\bar{X}_n] = \frac{\sigma^2}{n}$. L'Errore Standard (*Standard Error*, SE) è la deviazione standard dello stimatore:

$$\text{SE}(\bar{X}_n) = \sqrt{V[\bar{X}_n]} = \frac{\sigma}{\sqrt{n}}.$$

La **consistenza** richiede che lo stimatore converga in probabilità al parametro vero per $n \rightarrow \infty$ ($\bar{X}_n \xrightarrow{p} \mu$). Un criterio fondamentale stabilisce che uno stimatore è consistente se il suo Errore Quadratico Medio (*Mean Squared Error*, MSE) tende a zero al tendere di n all'infinito. Sappiamo che l'MSE si scompone come:

$$\text{MSE}(\bar{X}_n) = V[\bar{X}_n] + [\text{Bias}(\bar{X}_n)]^2.$$

Poiché lo stimatore è non distorto, il suo $\text{Bias}(\bar{X}_n) = E[\bar{X}_n] - \mu = 0$ per ogni n . Di conseguenza, l'MSE coincide esattamente con la varianza, ovvero con il quadrato dello Standard Error:

$$\text{MSE}(\bar{X}_n) = V[\bar{X}_n] = [\text{SE}(\bar{X}_n)]^2 = \frac{\sigma^2}{n}.$$

Calcoliamo ora il limite per $n \rightarrow \infty$ dello Standard Error:

$$\lim_{n \rightarrow \infty} \text{SE}(\bar{X}_n) = \lim_{n \rightarrow \infty} \frac{\sigma}{\sqrt{n}} = 0.$$

Poiché $\lim_{n \rightarrow \infty} \text{SE}(\bar{X}_n) = 0$, ne consegue direttamente che $\lim_{n \rightarrow \infty} \text{MSE}(\bar{X}_n) = 0$. La convergenza in media quadratica ($\text{MSE} \rightarrow 0$) è una condizione sufficiente che garantisce la convergenza in probabilità. Pertanto, l'annullarsi dell'errore standard all'infinito combinato con l'assenza di distorsione **dimostra la consistenza dello stimatore senza ricorrere alla disuguaglianza di Chebyshev**.

Soluzione Esercizio 2

- (a) Abbiamo una popolazione Normale con varianza σ^2 non nota e una piccola ampiezza campionaria ($n = 16 < 30$). Pertanto, si deve utilizzare la distribuzione t di Student con $\nu = n - 1 = 15$ gradi di libertà. Il livello di confidenza richiesto è $1 - \alpha = 0.95 \implies \alpha = 0.05$, da cui $\alpha/2 = 0.025$. Dalle tavole della distribuzione t di Student per $\nu = 15$ e una coda pari a 0.025, otteniamo il valore critico:

$$t_{15,0.025} = 2.131.$$

La formula per l'intervallo di confidenza della media è:

$$\text{IC} = \bar{x} \pm t_{n-1,\alpha/2} \cdot \frac{s}{\sqrt{n}}$$

Sostituendo i valori numerici:

$$\text{IC} = 4.5 \pm 2.131 \cdot \frac{1.2}{\sqrt{16}} = 4.5 \pm 2.131 \cdot \frac{1.2}{4} = 4.5 \pm 2.131 \cdot 0.3 = 4.5 \pm 0.6393.$$

L'intervallo di confidenza al 95% è quindi:

$$\text{IC} = [4.5 - 0.6393; 4.5 + 0.6393] = [3.8607; 5.1393] \text{ ore.}$$

- (b) Il margine di errore desiderato è $E = 0.3$. Utilizzando l'approssimazione normale standard (come da prassi per la pianificazione dell'ampiezza campionaria), per un livello di confidenza del 95%, abbiamo $z_{\alpha/2} = z_{0.025} = 1.96$. La formula per l'ampiezza campionaria minima è:

$$n = \left(\frac{z_{\alpha/2} \cdot \sigma}{E} \right)^2$$

Utilizzando $s = 1.2$ al posto di σ :

$$n = \left(\frac{1.96 \cdot 1.2}{0.3} \right)^2 = (1.96 \cdot 4)^2 = (7.84)^2 = 61.4656.$$

Arrotondando sempre all'intero superiore per garantire la precisione richiesta:

$$n_{\min} = 62.$$

Sarà necessario campionare almeno 62 studenti.

Soluzione Esercizio 3

- (a) L'affermazione dell'azienda definisce lo status quo, quindi viene posta all'ipotesi nulla. Trattandosi di verificare se la percentuale superi il limite del 2%, impostiamo un test unilaterale destro:

$$\begin{cases} H_0 : p \leq 0.02 & (\text{il reclamo è vero}) \\ H_1 : p > 0.02 & (\text{la percentuale di difetti è superiore}) \end{cases}$$

La proporzione campionaria è $\hat{p} = \frac{18}{600} = 0.03$.

Sotto l'ipotesi nulla, assumiamo lo scenario peggiore sulla frontiera, ovvero $p_0 = 0.02$. La statistica test Z per grandi campioni è data da:

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} = \frac{0.03 - 0.02}{\sqrt{\frac{0.02 \cdot 0.98}{600}}} = \frac{0.01}{\sqrt{\frac{0.0196}{600}}} = \frac{0.01}{\sqrt{0.00003267}} = \frac{0.01}{0.005715} \approx 1.750.$$

Il test è a una coda (destra), quindi il p -value è l'area a destra di $Z = 1.75$ sotto la curva Normale Standard $\mathcal{N}(0, 1)$:

$$p\text{-value} = P(Z > 1.75) = 1 - \Phi(1.75).$$

Dalle tavole della Normale Standard, sappiamo che $\Phi(1.75) = 0.9599$. Pertanto:

$$p\text{-value} = 1 - 0.9599 = 0.0401 \quad (4.01\%).$$

- (b) Dato un livello di significatività $\alpha = 0.05$ per un test a una coda a destra, cerchiamo il valore critico z_α tale che $P(Z > z_\alpha) = 0.05$, ovvero $\Phi(z_\alpha) = 0.95$. Dalle tavole della Normale Standard si ricava:

$$z_{0.05} = 1.645.$$

La regione di rifiuto del test è definita da tutte le statistiche test tali per cui $Z > 1.645$.

- (c) Confrontiamo la statistica test con il valore critico: poiché $Z_{\text{calc}} = 1.75 > 1.645$, la statistica cade nella regione di rifiuto.

Equivalentemente, analizzando il p -value, notiamo che $p\text{-value} = 0.0401 < 0.05$.

Di conseguenza, **rifiutiamo l'ipotesi nulla** H_0 al livello di significatività del 5%. Concludiamo che vi è evidenza statistica sufficiente per smentire l'affermazione dell'azienda: il tasso di componenti difettosi è significativamente superiore al 2%.