

Università degli Studi

Corso di Laurea in Informatica

Metodi Statistici per l'Informatica

Simulazione della Seconda Prova Parziale (Mock Test #3)

Nome e Cognome: _____

Numero di Matricola: _____

N.B. *Tutte le risposte devono essere adeguatamente giustificate. Prestare massima attenzione alle ipotesi sui parametri della popolazione e alla scelta delle distribuzioni di riferimento, come evidenziato a lezione.*

Esercizio 1 (Stima Puntuale e Errore Quadratico Medio) — [Totale: 6 punti]

Sia X_1, X_2, X_3 un campione casuale estratto da una popolazione con media $E[X_i] = \theta$ e varianza $V[X_i] = \sigma^2$. Si considerino i seguenti due stimatori per il parametro θ :

$$\hat{\theta}_1 = \frac{X_1 + X_2 + X_3}{3}$$
$$\hat{\theta}_2 = \frac{X_1 + X_2}{3}$$

- (a) Calcolare il Bias (distorsione) di entrambi gli stimatori. Uno dei due è non distorto (*unbiased*)? [2]
- (b) Calcolare la varianza di entrambi gli stimatori in funzione di σ^2 . [2]
- (c) Determinare l'Errore Quadratico Medio (MSE) di entrambi gli stimatori. Sotto quali condizioni (ovvero per quali valori di θ in relazione a σ^2) lo stimatore $\hat{\theta}_2$ risulta preferibile rispetto a $\hat{\theta}_1$ secondo il criterio del minimo MSE? [2]

Esercizio 2 (Intervalli di Confidenza e Pianificazione Campionaria) — [Totale: 6 punti]

- (a) Un amministratore di sistema vuole stimare il tempo medio di risposta di un server web. Viene estratto un campione casuale di $n = 16$ richieste indipendenti, ottenendo un tempo medio campionario $\bar{x} = 120$ ms e una deviazione standard campionario $s = 15$ ms. Assumendo che il tempo di risposta segua una distribuzione Normale, determinare un intervallo di confidenza al 95% per il vero tempo medio di risposta della popolazione μ . [3]
- (b) In un secondo studio, si desidera pianificare un'indagine per stimare la vera *proporzione* p di pacchetti di rete che subiscono un ritardo critico. Non avendo a disposizione alcuna informazione o stima preliminare sul valore di p , determinare l'ampiezza campionaria minima n affinché il margine di errore della stima non superi il 5% (0.05) con un livello di confidenza del 95%. [3]

Esercizio 3 (Test d'Ipotesi sulla Proporzione) — [Totale: 6 punti]

Una software house dichiara che il proprio framework produce moduli software con una proporzione massima di bug pari al 4% ($p \leq 0.04$). Un ente di certificazione indipendente analizza un campione casuale di $n = 400$ moduli indipendenti prodotti dal framework e riscontra la presenza di 24 moduli difettosi (con bug).

- (a) Formulare il sistema di ipotesi idoneo a verificare se la proporzione di moduli con bug sia significativamente superiore a quanto dichiarato dalla software house. [1]
- (b) Calcolare il valore della statistica test ottimale sotto l'ipotesi nulla H_0 e determinare il corrispondente p -value. [3]
- (c) Fissato un livello di significatività $\alpha = 0.05$, si rifiuti o meno l'ipotesi nulla? Qual è la conclusione del test in termini operativi? [2]

Soluzioni Dettagliate e Passaggi Svolti

Soluzione Esercizio 1

- (a) Il Bias (distorzione) di uno stimatore è definito come $B(\hat{\theta}) = E[\hat{\theta}] - \theta$.

$$E[\hat{\theta}_1] = E\left[\frac{X_1 + X_2 + X_3}{3}\right] = \frac{E[X_1] + E[X_2] + E[X_3]}{3} = \frac{\theta + \theta + \theta}{3} = \theta.$$

Dato che $E[\hat{\theta}_1] = \theta$, il suo bias è nullo: $B(\hat{\theta}_1) = 0$ ($\hat{\theta}_1$ è **non distorto**).

$$E[\hat{\theta}_2] = E\left[\frac{X_1 + X_2}{3}\right] = \frac{E[X_1] + E[X_2]}{3} = \frac{\theta + \theta}{3} = \frac{2}{3}\theta.$$

Il bias del secondo stimatore è: $B(\hat{\theta}_2) = \frac{2}{3}\theta - \theta = -\frac{1}{3}\theta$ ($\hat{\theta}_2$ è **distorto**).

- (b) Calcoliamo le varianze ricordando che le variabili del campione sono indipendenti, per cui $V[X_i] = \sigma^2$:

$$V[\hat{\theta}_1] = V\left[\frac{1}{3}(X_1 + X_2 + X_3)\right] = \frac{1}{9}(V[X_1] + V[X_2] + V[X_3]) = \frac{3}{9}\sigma^2 = \frac{1}{3}\sigma^2.$$

$$V[\hat{\theta}_2] = V\left[\frac{1}{3}(X_1 + X_2)\right] = \frac{1}{9}(V[X_1] + V[X_2]) = \frac{2}{9}\sigma^2.$$

- (c) L'Errore Quadratico Medio (MSE) si calcola come $MSE(\hat{\theta}) = V[\hat{\theta}] + [B(\hat{\theta})]^2$.

$$MSE(\hat{\theta}_1) = V[\hat{\theta}_1] + 0 = \frac{1}{3}\sigma^2 = \frac{3}{9}\sigma^2.$$

$$MSE(\hat{\theta}_2) = V[\hat{\theta}_2] + [B(\hat{\theta}_2)]^2 = \frac{2}{9}\sigma^2 + \left(-\frac{1}{3}\theta\right)^2 = \frac{2}{9}\sigma^2 + \frac{1}{9}\theta^2.$$

Lo stimatore $\hat{\theta}_2$ è preferibile a $\hat{\theta}_1$ se ha un MSE strettamente minore:

$$MSE(\hat{\theta}_2) < MSE(\hat{\theta}_1) \iff \frac{2}{9}\sigma^2 + \frac{1}{9}\theta^2 < \frac{3}{9}\sigma^2 \iff \frac{1}{9}\theta^2 < \frac{1}{9}\sigma^2 \iff \theta^2 < \sigma^2 \iff |\theta| < \sigma.$$

Nota del Professore: Se lo stimatore è non distorto, l'MSE coincide esattamente con la varianza. Se è distorto, la varianza da sola non basta per fare confronti: è fondamentale aggiungere il quadrato del bias. In questo caso, se il parametro incognito θ è piccolo rispetto alla deviazione standard ($|\theta| < \sigma$), accettare una piccola distorsione ci restituisce un vantaggio maggiore in termini di riduzione della varianza!

Soluzione Esercizio 2

- (a) Analizziamo i dati del problema: la varianza della popolazione σ^2 è **ignota**, la popolazione è normale e l'ampiezza campionaria è piccola: $n = 16 < 30$.

Nota del Professore (ATTENZIONE!): Quando la varianza della popolazione non è nota e il campione è piccolo ($n < 30$), non si può usare la distribuzione Normale Standard (Z). È obbligatorio ricorrere alla distribuzione t di Student con $n - 1$ gradi di libertà!

Gradi di libertà: $\nu = n - 1 = 15$. Per un livello di confidenza del 95%, l'errore è $\alpha = 0.05$, quindi $\alpha/2 = 0.025$. Dalle tavole della t di Student, il valore critico è: $t_{15, 0.025} = 2.131$. L'errore standard della media campionaria è: $SE = \frac{s}{\sqrt{n}} = \frac{15}{\sqrt{16}} = \frac{15}{4} = 3.75$. Il margine di errore è:

$$E = t_{15, 0.025} \cdot \frac{s}{\sqrt{n}} = 2.131 \cdot 3.75 = 7.99125 \approx 7.99 \text{ ms.}$$

L'intervallo di confidenza al 95% è:

$$IC_{95\%} = [\bar{x} - E; \bar{x} + E] = [120 - 7.99; 120 + 7.99] = [112.01; 127.99] \text{ ms.}$$

- (b) Dobbiamo determinare l'ampiezza campionaria n per una proporzione con margine di errore $E = 0.05$ al 95% di confidenza ($z_{0.025} = 1.96$). La formula è: $n = z_{\alpha/2}^2 \frac{p(1-p)}{E^2}$.

Nota del Professore: Se non viene fornita alcuna stima preliminare (proporzione pilota o storica), ci si deve mettere cautelativamente nella situazione peggiore (worst-case scenario). Il prodotto $p(1-p)$ è massimo quando $p = 0.5$ (infatti $0.5 \times 0.5 = 0.25$). Qualsiasi altro valore di p richiederebbe un campione più piccolo, quindi usando 0.5 siamo certi che il campione sarà sufficientemente grande.

Sostituendo i valori:

$$n = (1.96)^2 \cdot \frac{0.5 \cdot 0.5}{(0.05)^2} = 3.8416 \cdot \frac{0.25}{0.0025} = 3.8416 \cdot 100 = 384.16.$$

Arrotondando sempre all'intero superiore per garantire la precisione minima: $n_{\min} = 385$.

Soluzione Esercizio 3

- (a) Vogliamo verificare se vi è evidenza che la proporzione reale p superi la soglia massima dichiarata del 4%. Il sistema di ipotesi sarà dunque **unidirezionale destro**:

$$\begin{cases} H_0 : p = 0.04 & \text{(la dichiarazione è valida)} \\ H_1 : p > 0.04 & \text{(la percentuale di bug è superiore al dichiarato)} \end{cases}$$

- (b) Calcoliamo la proporzione campionaria: $\hat{p} = \frac{x}{n} = \frac{24}{400} = 0.06$.

Nota del Professore (ERRORE GRAVISSIMO DA EVITARE): Nel test d'ipotesi sulla proporzione, l'errore standard al denominatore della statistica test va calcolato sotto l'ipotesi nulla H_0 , cioè usando il valore teorico $p_0 = 0.04$, e **NON** la proporzione campionaria $\hat{p} = 0.06$! La proporzione campionaria si usa solo negli intervalli di confidenza dove la vera p è totalmente incognita. Sotto H_0 , assumiamo che $p = p_0$.

L'errore standard corretto sotto H_0 è:

$$SE_{H_0} = \sqrt{\frac{p_0(1-p_0)}{n}} = \sqrt{\frac{0.04 \cdot 0.96}{400}} = \sqrt{\frac{0.0384}{400}} = \sqrt{0.000096} \approx 0.009798.$$

La statistica test Z vale:

$$Z_{\text{calc}} = \frac{\hat{p} - p_0}{SE_{H_0}} = \frac{0.06 - 0.04}{0.009798} = \frac{0.02}{0.009798} \approx 2.041.$$

Trattandosi di un test a una coda a destra, il p -value è l'area a destra della statistica test calcolata sulla Normale Standard:

$$p\text{-value} = P(Z > 2.041) = 1 - \Phi(2.041).$$

Dalle tavole, $\Phi(2.04) \approx 0.9793$. Quindi: $p\text{-value} = 1 - 0.9793 = 0.0207$ (2.07%).

- (c) Confrontiamo il p -value con il livello di significatività scelto $\alpha = 0.05$:

$$p\text{-value} = 0.0207 < 0.05 = \alpha.$$

In alternativa, il valore critico per un test a una coda a destra ad $\alpha = 0.05$ è $z_{0.05} = 1.645$. Poiché $Z_{\text{calc}} = 2.041 > 1.645$, la statistica cade nella regione di rifiuto.

Conclusione: Rifiutiamo l'ipotesi nulla H_0 . Esiste una significativa evidenza statistica, al livello del 5%, per affermare che il framework produce una percentuale di bug superiore al 4% dichiarato.