

Università degli Studi

Corso di Laurea in Informatica

Metodi Statistici per l'Informatica

Simulazione della Seconda Prova Parziale (Mock Test #6)

Nome e Cognome: _____

Numero di Matricola: _____

N.B. Svolgere i seguenti quattro quesiti motivando in modo chiaro ed esauriente i passaggi matematici e logici intrapresi. Non è consentito l'uso di appunti o dispositivi elettronici, fatta eccezione per le tavole statistiche e una calcolatrice scientifica non programmabile.

Esercizio 1 — [Totale: 6 punti]

Sia X_1, X_2 un campione casuale di ampiezza $n = 2$ estratto da una popolazione avente media $E[X_i] = \theta$ e varianza $V[X_i] = \sigma^2$. Si intende valutare la bontà di due differenti stimatori candidati alla stima del parametro θ :

$$\hat{\theta}_1 = \frac{X_1 + X_2}{2}, \quad \hat{\theta}_2 = \frac{X_1 + X_2}{3}$$

- (a) Calcolare il Bias (distorsione) di entrambi gli stimatori. Sulla base del risultato ottenuto, stabilire se gli stimatori sono non distorti. [/1.5]
- (b) Determinare l'Errore Quadratico Medio (MSE) di $\hat{\theta}_1$ e di $\hat{\theta}_2$ in funzione di θ e σ^2 . [/2.5]
- (c) Stabilire per quali valori del parametro della popolazione θ (espressi in relazione a σ^2) lo stimatore $\hat{\theta}_2$ risulta preferibile a $\hat{\theta}_1$ in termini di Errore Quadratico Medio. [/2]

Esercizio 2 — [Totale: 5 points]

Un responsabile del controllo di gestione acquisisce un campione casuale di $n = 100$ moduli hardware per stimarne il peso medio della popolazione. L'intervallo di confidenza finale ottenuto è pari a:

$$IC = [49.342 \text{ g}; 50.658 \text{ g}]$$

Nel report generato, il software omette di stampare sia la deviazione standard della popolazione (σ) sia la media campionaria estratta ($\bar{x}$). È noto unicamente che il livello di confidenza associato alla procedura di calcolo è pari al 90%.

- (a) Individuare il valore della media campionaria $\bar{x}$ e il margine di errore E dell'intervallo. [/1.5]
- (b) Ricavare il valore numerico esatto della deviazione standard della popolazione σ ipotizzato per la costruzione dell'intervallo. [/2]
- (c) Supponendo che si desideri dimezzare il margine di errore precedentemente calcolato, mantenendo inalterato sia il livello di confidenza al 90% sia la deviazione standard σ , calcolare quale deve essere la nuova ampiezza campionaria n' minima richiesta. [/1.5]

Esercizio 3 — [Totale: 5 punti]

In un'infrastruttura cloud, il tempo di risposta di un server in condizioni di regime normale segue una distribuzione normale con media $\mu = 200$ ms e deviazione standard nota $\sigma = 40$ ms. Per rilevare tempestivamente rallentamenti anomali, si formula un test basato sul seguente sistema di ipotesi:

$$\begin{cases} H_0 : \mu = 200 \\ H_1 : \mu > 200 \end{cases}$$

L'analisi viene condotta su un campione di ampiezza $n = 64$ richieste indipendenti, fissando a priori un livello di significatività $\alpha = 0.01$.

- (a) Determinare la regione di rifiuto per il test espressa come valore di soglia limite ($\bar{x}_{crit}$) per la media campionaria osservata $\bar{X}$. [/1.5]
- (b) Supponendo che il sistema stia effettivamente subendo un degradamento prestazionale tale per cui il vero valore della media della popolazione sia slittato a $\mu_1 = 215$ ms, calcolare la probabilità di non rifiutare l'ipotesi nulla. [/2.5]
- (c) Calcolare la potenza del test associata alla configurazione descritta al punto (b) e commentarne brevemente il significato operativo. [/1]

Esercizio 4 — [Totale: 5 punti]

Un analista di rete monitora il traffico dati giornaliero (espresso in Terabyte) su una tratta di dorsale. Si imposta un test sulle ipotesi $H_0 : \mu = 80$ contro $H_1 : \mu \neq 80$, assumendo una deviazione standard nota della popolazione $\sigma = 12$ e un'ampiezza campionaria pari a $n = 36$. L'analista sceglie di implementare la seguente regola operativa: *"L'ipotesi nulla H_0 verrà respinta ogniqualvolta lo scostamento in valore assoluto tra la media campionaria osservata e il valore sotto ipotesi nulla risulterà superiore a 4.5"* (ovvero se $|\bar{X} - 80| > 4.5$).

- (a) Determinare la probabilità di commettere un errore di primo tipo associata alla regola operativa definita dall'analista. [/2.5]
- (b) Qualora l'analista decidesse di rendere il criterio di rifiuto più restrittivo modificando la condizione in $|\bar{X} - 80| > 5.16$, quale diverrebbe il corrispondente livello di significatività del test? [/2.5]

Soluzioni Dettagliate e Passaggi Svolti

Soluzione Esercizio 1

(a) Calcoliamo i valori attesi dei due stimatori per trovarne la distorsione:

$$E[\hat{\theta}_1] = E\left[\frac{X_1 + X_2}{2}\right] = \frac{E[X_1] + E[X_2]}{2} = \frac{\theta + \theta}{2} = \theta.$$

La distorsione di $\hat{\theta}_1$ è quindi:

$$B(\hat{\theta}_1) = E[\hat{\theta}_1] - \theta = \theta - \theta = \mathbf{0}.$$

Lo stimatore $\hat{\theta}_1$ è **non distorto** (*unbiased*).

Per il secondo stimatore:

$$E[\hat{\theta}_2] = E\left[\frac{X_1 + X_2}{3}\right] = \frac{E[X_1] + E[X_2]}{3} = \frac{\theta + \theta}{3} = \frac{2}{3}\theta.$$

La distorsione di $\hat{\theta}_2$ è quindi:

$$B(\hat{\theta}_2) = E[\hat{\theta}_2] - \theta = \frac{2}{3}\theta - \theta = -\frac{1}{3}\theta.$$

Lo stimatore $\hat{\theta}_2$ è **distorto** (*biased*), con una distorsione che dipende linearmente dal valore reale θ .

(b) L'Errore Quadratico Medio (MSE) si calcola tramite la scomposizione fondamentale: $\text{MSE}(\hat{\theta}) = V[\hat{\theta}] + [B(\hat{\theta})]^2$.

Per lo stimatore $\hat{\theta}_1$ (indipendenza campionaria implica $V[X_i] = \sigma^2$):

$$V[\hat{\theta}_1] = V\left[\frac{X_1 + X_2}{2}\right] = \frac{1}{4}(V[X_1] + V[X_2]) = \frac{\sigma^2 + \sigma^2}{4} = \frac{\sigma^2}{2}.$$

Dato che $B(\hat{\theta}_1) = 0$:

$$\text{MSE}(\hat{\theta}_1) = \frac{\sigma^2}{2} + 0^2 = \frac{1}{2}\sigma^2 \quad (\text{o } 0.5\sigma^2).$$

Per lo stimatore $\hat{\theta}_2$:

$$V[\hat{\theta}_2] = V\left[\frac{X_1 + X_2}{3}\right] = \frac{1}{9}(V[X_1] + V[X_2]) = \frac{\sigma^2 + \sigma^2}{9} = \frac{2}{9}\sigma^2.$$

Avendo trovato $B(\hat{\theta}_2) = -\frac{1}{3}\theta$, ricaviamo:

$$\text{MSE}(\hat{\theta}_2) = V[\hat{\theta}_2] + [B(\hat{\theta}_2)]^2 = \frac{2}{9}\sigma^2 + \left(-\frac{1}{3}\theta\right)^2 = \frac{2}{9}\sigma^2 + \frac{1}{9}\theta^2.$$

(c) Lo stimatore $\hat{\theta}_2$ risulta preferibile a $\hat{\theta}_1$ se e solo se presenta un errore quadratico medio strettamente minore, ossia se $\text{MSE}(\hat{\theta}_2) < \text{MSE}(\hat{\theta}_1)$:

$$\frac{2}{9}\sigma^2 + \frac{1}{9}\theta^2 < \frac{1}{2}\sigma^2.$$

Isoliamo il termine contenente il parametro θ^2 :

$$\frac{1}{9}\theta^2 < \frac{1}{2}\sigma^2 - \frac{2}{9}\sigma^2 \implies \frac{1}{9}\theta^2 < \left(\frac{9-4}{18}\right)\sigma^2 \implies \frac{1}{9}\theta^2 < \frac{5}{18}\sigma^2.$$

Moltiplicando ambo i membri per 9:

$$\theta^2 < 9 \cdot \frac{5}{18} \sigma^2 \implies \theta^2 < \frac{5}{2} \sigma^2.$$

Estraendo la radice quadrata su entrambi i lati, si ottiene la condizione finale di preferibilità:

$$|\theta| < \sqrt{2.5} \sigma \quad \left(\text{ovvero } -\sqrt{2.5} \sigma < \theta < \sqrt{2.5} \sigma \right).$$

Nota di commento: Lo stimatore distorto è migliore di quello non distorto quando il parametro θ è vicino all'origine, in quanto la forte riduzione di varianza ($\frac{2}{9} \sigma^2 < \frac{1}{2} \sigma^2$) compensa abbondantemente l'introduzione della distorsione quadratica.

Soluzione Esercizio 2

- (a) Per motivi di simmetria dell'intervallo basato sulla statistica pivotale normale, la media campionaria $\bar{x}$ coincide con il punto medio esatto della struttura intervallare:

$$\bar{x} = \frac{\text{Estremo Inferiore} + \text{Estremo Superiore}}{2} = \frac{49.342 + 50.658}{2} = \frac{100.000}{2} = \mathbf{50 \text{ g.}}$$

Il margine di errore E corrisponde alla semiampiezza dell'intervallo stesso:

$$E = \text{Estremo Superiore} - \bar{x} = 50.658 - 50 = \mathbf{0.658 \text{ g.}}$$

- (b) L'intervallo di confidenza per la media con σ nota si avvale del quantile della distribuzione normale standard. Per un livello di confidenza del 90%, l'area d'errore totale è $\alpha = 0.10$, equamente ripartita sulle due code ($\alpha/2 = 0.05$). Dalle tavole statistiche, ricaviamo il valore critico $z_{0.05} = 1.645$.

La formula analitica del margine di errore è:

$$E = z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}.$$

Sostituendo i valori noti ($E = 0.658$, $z_{\alpha/2} = 1.645$, $n = 100 \implies \sqrt{n} = 10$):

$$0.658 = 1.645 \cdot \frac{\sigma}{10} \implies 0.658 = 0.1645 \cdot \sigma.$$

Risolvendo rispetto a σ :

$$\sigma = \frac{0.658}{0.1645} = \mathbf{4 \text{ g.}}$$

- (c) Denotiamo il nuovo margine di errore desiderato come $E' = \frac{E}{2} = \frac{0.658}{2} = 0.329$. Impostiamo l'equazione per la nuova ampiezza campionaria n' :

$$E' = z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n'}} \implies \sqrt{n'} = \frac{z_{\alpha/2} \cdot \sigma}{E'}.$$

Sostituiamo i valori numerici:

$$\sqrt{n'} = \frac{1.645 \cdot 4}{0.329} = \frac{6.58}{0.329} = 20.$$

Elevando al quadrato per ricavare n' :

$$n' = 20^2 = \mathbf{400}.$$

Via analitica rapida: Poiché il margine di errore E è inversamente proporzionale alla radice quadrata di n ($E \propto 1/\sqrt{n}$), per dimezzare il margine di errore ($1/2$) è matematicamente necessario quadruplicare l'ampiezza del campione ($2^2 = 4$). Di conseguenza, $n' = 4 \cdot 100 = 400$.

Soluzione Esercizio 3

- (a) Sotto l'assunto di validità dell'ipotesi nulla H_0 , la media della popolazione è $\mu_0 = 200$ ms. La distribuzione campionaria della media si profila come $\bar{X} \sim N\left(\mu_0, \frac{\sigma}{\sqrt{n}}\right)$.

Calcoliamo il corrispondente Errore Standard (SE):

$$SE = \frac{\sigma}{\sqrt{n}} = \frac{40}{\sqrt{64}} = \frac{40}{8} = 5 \text{ ms.}$$

Il test è di tipo unidirezionale destro. Dato un livello di significatività $\alpha = 0.01$, cerchiamo sulle tavole della normale standard il quantile $z_{0.01}$ tale per cui $P(Z > z_{0.01}) = 0.01$, ottenendo $z_{0.01} = 2.33$.

La regione di rifiuto convertita in valori della media campionaria è definita da $\bar{X} > \bar{x}_{crit}$:

$$\bar{x}_{crit} = \mu_0 + z_{0.01} \cdot SE = 200 + 2.33 \cdot 5 = 200 + 11.65 = \mathbf{211.65} \text{ ms.}$$

La regione di rifiuto è: $\bar{X} > \mathbf{211.65}$ ms.

- (b) L'errore di secondo tipo (β) corrisponde alla probabilità di non rifiutare l'ipotesi nulla H_0 laddove lo scenario reale rispecchi l'ipotesi alternativa H_1 ($\mu_1 = 215$ ms). La regola di non rifiuto è $\bar{X} \leq 211.65$.

Calcoliamo la probabilità centrando la distribuzione sul nuovo baricentro reale $\mu_1 = 215$ (mantenendo inalterato l'errore standard $SE = 5$):

$$\beta = P(\bar{X} \leq 211.65 \mid \mu = 215) = P\left(Z \leq \frac{211.65 - \mu_1}{SE}\right) = P\left(Z \leq \frac{211.65 - 215}{5}\right)$$

$$\beta = P\left(Z \leq \frac{-3.35}{5}\right) = P(Z \leq -0.67).$$

Consultando le tavole della Normale Standard per il valore $Z = -0.67$, si ottiene l'area cumulata:

$$\beta = \Phi(-0.67) = \mathbf{0.2514} \quad (\text{ossia } \mathbf{25.14\%}).$$

- (c) La potenza del test è la probabilità complementare all'errore di secondo tipo, definita come la capacità del test di respingere correttamente H_0 quando essa è falsa:

$$\text{Potenza} = 1 - \beta = 1 - 0.2514 = \mathbf{0.7486} \quad (\text{ossia } \mathbf{74.86\%}).$$

Significato operativo: Qualora le performance del server cloud subissero effettivamente un rallentamento medio pari a 215 ms, la procedura statistica sarà in grado di intercettare tale anomalia e rifiutare correttamente H_0 nel 74.86% dei controlli effettuati. Nel restante 25.14% dei casi, il test fallirà il rilevamento (generando un falso negativo).

Soluzione Esercizio 4

- (a) Il livello di significatività α rappresenta la probabilità di incorrere in un errore di primo tipo, rifiutando H_0 quando essa è valida ($\mu_0 = 80$).

Calcoliamo innanzitutto l'Errore Standard associato alle medie campionarie:

$$SE = \frac{\sigma}{\sqrt{n}} = \frac{12}{\sqrt{36}} = \frac{12}{6} = 2.$$

La regola di rifiuto impostata in valore assoluto configura un test bidirezionale, equivalente a respingere H_0 se $\bar{X} - 80 < -4.5$ oppure se $\bar{X} - 80 > 4.5$. Esprimiamo la probabilità sotto l'ipotesi $\mu = 80$:

$$\alpha = P(|\bar{X} - 80| > 4.5 \mid \mu = 80) = P\left(\left|\frac{\bar{X} - 80}{2}\right| > \frac{4.5}{2}\right) = P(|Z| > 2.25).$$

Sfruttando la simmetria della distribuzione normale standard:

$$\alpha = 2 \cdot P(Z > 2.25) = 2 \cdot [1 - \Phi(2.25)].$$

Leggendo sulle tavole il valore di $\Phi(2.25) = 0.9878$, otteniamo:

$$\alpha = 2 \cdot (1 - 0.9878) = 2 \cdot 0.0122 = \mathbf{0.0244} \quad (\text{ossia } \mathbf{2.44\%}).$$

- (b) Se la soglia limite dello scostamento viene elevata a 5.16, la nuova probabilità di rifiuto sotto H_0 si ricava riconducendosi nuovamente alla variabile standardizzata Z :

$$\alpha' = P(|\bar{X} - 80| > 5.16 \mid \mu = 80) = P\left(|Z| > \frac{5.16}{2}\right) = P(|Z| > 2.58).$$

Sempre per motivi di simmetria bilaterale:

$$\alpha' = 2 \cdot [1 - \Phi(2.58)].$$

Dalle tavole statistiche individuiamo l'area cumulata $\Phi(2.58) = 0.9951$. Pertanto:

$$\alpha' = 2 \cdot (1 - 0.9951) = 2 \cdot 0.0049 = \mathbf{0.0098} \quad (\text{ovvero } \mathbf{0.98\%} \approx \mathbf{1\%}).$$

Innalzando la soglia di tolleranza dello scostamento, l'analista riduce il livello di significatività all'1% circa, rendendo il test più restrittivo e diminuendo la probabilità di generare falsi allarmi.